

GraphRAG 多模型构建成本对比报告

Token 消耗与经费明细（按模型 / 按构建）

WeaverAgent 自动生成

2026 年 04 月 20 日

执行摘要

- 扫描的构建总数：**14**，其中成功产出实体表（entities.parquet）且含缓存的构建：**10**
- 累计处理文档数：**54** 篇
- 累计 LLM+Embedding token 消耗：**11,336,861** tokens
- 累计美元成本：**\$9.5855**
- 累计人民币成本：**¥18.5763**
- 人民币等值总成本（汇率 6.82）：**¥83.95**

1. 成功构建总览

构建 ID	LLM 模型	文档	输入 tok	输出 tok	耗时 (s)	成本 (¥)
a8d200294d3b	gpt-4o-mini	1	1,298,619	269,754	-	¥2.43
55f5bb2516d2	gpt-4o	2	1,939,415	335,486	-	¥55.47
7d9de8b6f876	gpt-5-mini	10	563,094	207,528	-	¥3.77
bae3c7c26ca1	qwen3.5-plus	5	1,531,023	333,209	987	¥7.06
1bc04e752fb9	glm-5-turbo	5	170,523	34,068	1378	¥1.58
47ddeb80f5f5	glm-5-turbo	10	407,506	92,544	3022	¥4.05
fc867e05c308	kimi-k2-turbo-preview	5	1,088,807	95,239	3060	¥5.88
0bb60bf501f1	gpt-4o-mini	5	1,105,386	65,803	446	¥1.38
ac1de00fd368	gpt-4o-mini	1	1,152,296	78,673	-	¥1.48
d8c85f6284c4	gpt-4o-mini	10	481,410	86,478	-	¥0.83
合计 (10 次)	-	54	9,738,079	1,598,782	-	¥83.95

注：所有成功构建按完成时间排序；成本栏为等值人民币（\$1 ≈ ¥6.82）。

2. 按 LLM 模型聚合

LLM 模型	供应商	构建	文档	输入 tok	输出 tok	成本 (¥)
gpt-4o	OpenAI	1	2	1,939,415	335,486	¥55.47
qwen3.5-plus	阿里 DashScope	1	5	1,531,023	333,209	¥7.06
gpt-4o-mini	OpenAI	4	17	4,037,711	500,708	¥6.13
kimi-k2-turbo-preview	Moonshot Kimi	1	5	1,088,807	95,239	¥5.88
glm-5-turbo	智谱 AI	2	15	578,029	126,612	¥5.64
gpt-5-mini	OpenAI	1	10	563,094	207,528	¥3.77

按 LLM 主模型聚合（Embedding 不单列；相同模型的不同日期版本合并）。

3. 每次构建明细（按模型拆分）

3.1 构建 weaveragent__a8d200294d3b4da2

完成时间 2026-04-19 22:42

文档数 1

LLM 模型 gpt-4o-mini

模型	调用	输入 tok	输出 tok	合计 tok	成本
gpt-4o-mini	785	1,298,619	269,754	1,568,373	\$0.3566
合计	785	1,298,619	269,754	1,568,373	\$0.3566 + ≈ ¥2.43

3.2 构建 weaveragent__55f5bb2516d246f9

完成时间 2026-04-19 22:47

文档数 2

LLM 模型 gpt-4o

Embedding 模型 text-embedding-3-small

模型	调用	输入 tok	输出 tok	合计 tok	成本
gpt-4o	1,161	1,911,119	335,486	2,246,605	\$8.1327
text-embedding-3-small	24	28,296	0	28,296	\$0.0006
合计	1,185	1,939,415	335,486	2,274,901	\$8.1332 + ≈ ¥55.47

3.3 构建 weaveragent__7d9de8b6f8764d78

完成时间 2026-04-20 00:58

文档数 10

LLM 模型 gpt-5-mini

Embedding 模型 text-embedding-3-small

模型	调用	输入 tok	输出 tok	合计 tok	成本
gpt-5-mini	333	552,577	207,528	760,105	\$0.5532
text-embedding-3-small	10	10,517	0	10,517	\$0.0002
合计	343	563,094	207,528	770,622	\$0.5534 + ≈ ¥3.77

3.4 构建 weaveragent__bae3c7c26ca14ea9

完成时间 2026-04-20 02:42

文档数 5

总耗时 987.5 s（约 16.5 分钟）

LLM 模型 qwen3.5-plus

模型	调用	输入 tok	输出 tok	合计 tok	成本
qwen3.5-plus	1,185	1,531,023	333,209	1,864,232	¥7.0606
合计	1,185	1,531,023	333,209	1,864,232	¥7.0606 + ≈ ¥7.06

3.5 构建 weaveragent__1bc04e752fb940d3

完成时间 2026-04-20 02:42

文档数 5

总耗时 1378.2 s（约 23.0 分钟）

LLM 模型 glm-5-turbo

Embedding 模型 embedding-3

模型	调用	输入 tok	输出 tok	合计 tok	成本
glm-5-turbo	137	166,121	34,068	200,189	¥1.5801
embedding-3	5	4,402	0	4,402	¥0.0022
合计	142	170,523	34,068	204,591	¥1.5823 + ≈ ¥1.58

3.6 构建 weaveragent__47ddbb80f5f546dd

完成时间 2026-04-20 02:42

文档数 10

总耗时 3022.3 s (约 50.4 分钟)

LLM 模型 glm-5-turbo

Embedding 模型 embedding-3

模型	调用	输入 tok	输出 tok	合计 tok	成本
glm-5-turbo	324	403,269	92,544	495,813	¥4.0523
embedding-3	5	4,237	0	4,237	¥0.0021
合计	329	407,506	92,544	500,050	¥4.0544 + ≈ ¥4.05

3.7 构建 weaveragent__fc867e05c30848f0

完成时间 2026-04-20 02:42

文档数 5

总耗时 3060.3 s (约 51.0 分钟)

LLM 模型 kimi-k2-turbo-preview

模型	调用	输入 tok	输出 tok	合计 tok	成本
kimi-k2-turbo-preview	1,009	1,088,807	95,239	1,184,046	¥5.8791
合计	1,009	1,088,807	95,239	1,184,046	¥5.8791 + ≈ ¥5.88

3.8 构建 weaveragent__0bb60bf501f14900

完成时间 2026-04-20 02:42

文档数 5

总耗时 446.4 s (约 7.4 分钟)

LLM 模型 gpt-4o-mini

Embedding 模型 text-embedding-3-small

模型	调用	输入 tok	输出 tok	合计 tok	成本
gpt-4o-mini	916	1,085,617	65,803	1,151,420	\$0.2023
text-embedding-3-small	23	19,769	0	19,769	\$0.0004
合计	939	1,105,386	65,803	1,171,189	\$0.2027 + $\approx$ ¥1.38

3.9 构建 weaveragent__ac1de00fd3684c35

完成时间2026-04-20 04:35

文档数1

LLM 模型gpt-4o-mini

Embedding 模型text-embedding-3-small

模型	调用	输入 tok	输出 tok	合计 tok	成本
gpt-4o-mini	926	1,132,580	78,673	1,211,253	\$0.2171
text-embedding-3-small	25	19,716	0	19,716	\$0.0004
合计	951	1,152,296	78,673	1,230,969	\$0.2175 + $\approx$ ¥1.48

3.10 构建 weaveragent__d8c85f6284c440fe

完成时间2026-04-20 17:19

文档数10

LLM 模型gpt-4o-mini

Embedding 模型text-embedding-3-small

模型	调用	输入 tok	输出 tok	合计 tok	成本
gpt-4o-mini	275	465,402	86,478	551,880	\$0.1217
text-embedding-3-small	17	16,008	0	16,008	\$0.0003
合计	292	481,410	86,478	567,888	\$0.1220 + $\approx$ ¥0.83

4. 定价参考

下表为本报告使用的单价（per 1K tokens）：

模型	供应商	输入单价	输出单价	货币
embedding-3	智谱 AI	¥0.0005	¥0	CNY
glm-5-turbo	智谱 AI	¥0.005	¥0.022	CNY
gpt-4o	OpenAI	\$0.0025	\$0.01	USD
gpt-4o-mini	OpenAI	\$0.00015	\$0.0006	USD
gpt-5-mini	OpenAI	\$0.00025	\$0.002	USD
kimi-k2-turbo-preview	Moonshot Kimi	¥0.004	¥0.016	CNY
qwen3.5-plus	阿里 DashScope	¥0.002	¥0.012	CNY
text-embedding-3-small	OpenAI	\$2e-05	\$0	USD

5. 观察与建议

- 在较大规模构建（≥ 5 文档）场景下，最便宜的配置是 **gpt-4o-mini-2024-07-18**（¥0.0832/文档），最贵的是 **qwen3.5-plus**（¥1.4121/文档），差距约 **17.0×**。
- gpt-4o-mini**：当前性价比最高的 OpenAI 选项（\$0.15/\$0.60 per M），本批次 5 篇文档的构建约 ¥1.4，适合批量索引。
- glm-5-turbo**：国产替代选项（¥5/¥22 per M），单价约为 gpt-4o-mini 的 5×，属中低成本区间；如网络策略不便直连 OpenAI，可用作降级方案（已启用 thinking=disabled 关闭思考）。
- gpt-5-mini**：已切换到 reasoning_effort=minimal（构建场景）/ low（对话），成本显著低于默认 medium 档，但比 gpt-4o-mini 仍略贵。
- gpt-4o**：质量最佳但单价约为 gpt-4o-mini 的 **16.7×**（\$2.50/\$10.00 vs \$0.15/\$0.60 per M），**不推荐用于批量索引**，仅建议用于最终报告生成或难例重试。
- Embedding 成本占比极小（通常 <1%），切换 embedding 模型对总账影响有限，主要决策应集中在 LLM 选择上。

本报告由 graphrag_data 目录自动扫描生成。定价为公开官方价，实际账单以供应商后台为准。